



Gestão de Dados e Big Data

Fundamentos de TI

Aula 26/36

Memória

Dado

Rede

Arm

Soc

Armazenamento

Hd

Conceito

Big Data se refere a conjuntos de dados tão grandes ou complexos que as ferramentas tradicionais não dão conta. É como tentar beber água de uma mangueira de incêndio — o volume é enorme. Caracterizado por 5 Vs: Volume (de terabytes a petabytes — 1 petabyte = 1.000 terabytes), Velocidade (dados gerados em tempo real — sensores, redes sociais), Variedade (dados estruturados como planilhas, semiestruturados como JSON, ou não estruturados como fotos), Veracidade (qualidade e confiabilidade dos dados) e Valor (os insights para o negócio). Tecnologias: Hadoop (armazenamento distribuído com HDFS e processamento com MapReduce), Spark (processamento em memória, mais rápido), bancos NoSQL (MongoDB, Cassandra), data lakes (armazena dados brutos) versus data warehouses (dados tratados para análise, como Snowflake, Redshift). O processo ETL (Extração, Transformação e Carga) integra dados de várias fontes. A análise de Big Data gera insights para negócios, ciência e governo — como nas recomendações da Netflix, Google Trends e previsão de epidemias.

Big Data

Volume

Veloc.

Varied.

Veracidade

+ Valor

Hadoop / Spark

Data Lake / Warehouse



Atividade Prática

Escolha um serviço digital que você usa (Netflix, Spotify, YouTube, Instagram, Google Maps) e analise como ele usa big data: (1) que dados coleta? (2) como processa para gerar recomendações? (3) como isso melhora (ou piora) sua experiência? (4) que questões de privacidade estão envolvidas?



Pesquisa

Pesquise o ecossistema Hadoop: HDFS (sistema de arquivos distribuído), MapReduce (processamento paralelo), YARN (gerenciamento de recursos) e ecosystem tools (Hive, Pig, HBase, Spark). Como o Hadoop possibilitou o processamento de big data em clusters de hardware commodity?