



Streaming de Dados e Data Mesh

Tópicos Avançados em TI

Aula 12/23

Sam

Conceito

Processamento de streaming é como assistir a um rio fluindo em vez de encher um balde e analisar a água parada: os dados são processados em tempo real, ao contrário de batch. Apache Kafka: plataforma de streaming distribuída com publish/subscribe, tópicos, partições, offsets, consumidores em grupo. Kafka Streams e ksqlDB processam streams dentro do Kafka. Apache Flink: processamento de streams com estado, exactly-once, event time processing, janelas (tumbling, sliding, session). Apache Spark Structured Streaming: micro-batches ou streaming contínuo. Data Mesh (Zhamak Dehghani, 2019) é um paradigma de arquitetura de dados descentralizado: domains ownership (times de negócio donos dos dados), data as a product (dados tratados como produto), self-serve data platform (plataforma de autoatendimento), federated computational governance (governança federada). Data Lakehouse (Databricks, Iceberg, Delta Lake) combina data lake (armazenamento barato) com funcionalidades de warehouse (ACID, schema enforcement).

Streaming

Producer

Kafka

Consumer

Flink / Spark Streaming

Data Mesh



Atividade Prática

Use o Confluent Cloud (camada gratuita) ou Apache Kafka local (Docker) para: (1) criar um tópico "pedidos", (2) produzir 10 mensagens JSON simulando pedidos, (3) consumir as mensagens em outro terminal. Depois, implemente um processamento simples com Kafka Streams: filtre pedidos com valor > R\$ 100 e conte por região.



Pesquisa

Pesquise o Data Mesh: por que Zhamak Dehghani propôs o paradigma (problemas do data lake centralizado), os 4 princípios (domain ownership, data product, self-serve platform, federated governance), e críticas (complexidade operacional, maturidade organizacional necessária).



Requisitos

Confluent Cloud (gratuito) ou Docker para Kafka local. Python com kafka-python ou Java.